

PRD — 쇼티지·병목 수혜주 스캐너 (Shortage/Bottleneck Scanner)

버전 0.1 (초안) · 작성일 2026-06-15 목적: 매주 뉴스·컨센서스에서 '쇼티지/병목' 테마를 자동 탐지하고, 관련 상장사 후보를 재무지표와 함께 리포트로 산출한다.

1. 개요 & 목적

웹 뉴스와 증권사 리포트 컨센서스(제목·요약 수준)에서 '병목', '쇼티지', '공급부족' 등의 테마를 주기적으로 수집·분석하여,

- 병목/쇼티지가 발생 중인 **섹터·키워드**를 추출하고
- 각 키워드와 연관된 **상장사 후보(수혜주 가설)**를 근거·연관도·시총·매출·PER과 함께 나열하며
- 이를 **매주 지정 요일에 자동 업데이트**한다.

제품 원칙: 출력되는 종목은 '검증된 스크리닝 후보(가설)'이며 투자 추천이 아니다. 리포트 상단에 이 점을 명시한다. 모든 재무 수치는 데이터 소스 기준이며 시차·오류 가능성을 표기한다.

2. 사용자 & 사용 시나리오

- 사용자:** 본인(개인 투자 리서치 용도). 단일 사용자 기준.
- 시나리오:** 매주 월요일 아침, 자동 생성된 HTML/Markdown 리포트를 확인해 한 주의 공급망 병목 테마와 관련 종목 후보를 빠르게 스캔한다.

3. 범위 (Scope)

포함 (In scope)

- 네이버 뉴스 검색 API 기반 기사 수집
- 한경 컨센서스 등 리포트 **제목·요약(코멘트) 수준** 수집
- LLM(Claude) 기반 테마·섹터 추출
- LLM 종목 후보 제안 + 실제 상장종목 리스트 대조 검증
- pykrx / DART 기반 시총·매출·PER 결합
- 주간 자동 실행 및 리포트 산출

제외 (Out of scope)

- 애널리스트 리포트 전문(PDF) 수집·파싱** — 명시적으로 포기
- 실시간/일간 모니터링 (주 1회 배치만)
- 자동 매매·주문 연동

- 종목 추천·매수 신호 생성
-

4. 핵심 기능 요구사항

Step 1 — 테마·키워드 추출

- **F1.1** 네이버 뉴스 API로 검색어 세트(쇼티지, 병목, 공급부족, 증설 지연, 리드타임, 감산 등 설정 파일로 관리)를 최근 N일(기본 7일) 범위로 조회한다.
- **F1.2** 한경 컨센서스에서 동일 키워드 관련 리포트 제목·요약을 크롤링한다.
- **F1.3** 수집 텍스트를 Claude에 전달해 "어떤 제품·소재·섹터에서 병목/쇼티지가 발생 중인 지"를 근거 문장과 함께 구조화 JSON으로 추출한다.
- **F1.4** 유사 키워드는 병합(dedup)하고, 근거 강도(confidence)를 high/medium/low로 부여한다.

Step 2 — 종목 매핑 & 재무 결합 (멀티 LLM 앙상블)

- **F2.1** 각 키워드별로 복수 LLM(Claude·GPT·Gemini)에 동일 프롬프트·동일 출력 스키마로 관련 상장사 후보를 제안받는다(종목명 + 연관 이유 + 연관도). 제안자(proposer)는 인터페이스로 추상화해 모델을 켜고/끄거나 추가할 수 있게 한다(설정 파일로 사용 모델 목록 관리).
- **F2.2** 각 모델이 제안한 종목명을 **KRX 상장종목 리스트**와 대조해 실재하는 종목코드로 정규화한다(미존재·중복명은 드롭 또는 플래그). 검증은 모델별 결과 각각에 적용한다.
- **F2.3 (앙상블 병합)** 정규화된 결과를 **종목코드 기준으로 dedup**하고, 어떤 모델이 제안했는지(proposed_by)와 합의도(agreement_score = 제안한 모델 수)를 기록한다. 연관 이유·연관도는 모델마다 다르므로, 병합 후 하나의 'judge' 모델이 최종 사유·연관도를 정리한다.
- **F2.4** 검증·병합된 종목에 대해 시총·매출(TTM)·PER을 한 번만 결합한다.
 - 시총·PER(TTM): pykrx (get_market_fundamental), (get_market_cap)
 - 매출(최근 4분기 합): OpenDART 분기 재무제표
 - (선택) 분기 연환산 PER: DART 최근 분기 순이익 × 4 ÷ 시총 — best-effort, 변동성 큼 표기
- **F2.5** 키워드당 종목은 합의도(agreement_score) → 연관도 순으로 정렬하고 상위 K개(기본 5)로 제한한다.

Step 3 — 스케줄링 & 산출

- **F3.1** 매주 지정 요일·시각에 전체 파이프라인을 자동 실행한다(기본: 매주 월 08:00 KST).
 - **F3.2** 결과를 HTML + Markdown 리포트로 저장한다.
 - **F3.3** (선택) 텔레그램 봇 또는 이메일로 리포트 요약을 발송한다.
 - **F3.4** 실행 이력·산출물을 날짜별로 보관한다(/reports/YYYY-MM-DD/).
-

5. 데이터 소스

소스	용도	접근	비고
네이버 검색 API (뉴스)	기사 수집	무료 API 키	일일 호출 한도 확인
한경 컨센서스	리포트 제목·요약	크롤링	전문 PDF 제외, robots/ 이용약관 확인
KRX 상장종목 리 스트	종목 검증	FinanceDataReader StockListing('KRX')	종목명→코드 매핑
pykrx	시총·PER(TTM)	무료	일자 지정 필요(휴장일 처리)
OpenDART	분기 매출·순이익	무료 API 키	분기 보고서 공시 시차 존재
Anthropic API (Claude)	테마 추출·종목 제 안·judge	API 키	model: claude 계열
OpenAI API (GPT)	종목 제안(양상블)	API 키	model: 최신 GPT 계열, 설정으로 관리
Google Gemini API	종목 제안(양상블)	API 키	model: 최신 Gemini 계 열, 설정으로 관리

6. 데이터 모델 (출력 스키마)

Step 1 산출

json

```

{
  "scan_date": "2026-06-16",
  "window_days": 7,
  "themes": [
    {
      "keyword": "MLCC 공급부족",
      "category": "전자부품/소재",
      "type": "shortage",
      "evidence": "AI 서버용 고용량 MLCC 주문 증가로 리드타임이 길어지고 있다는 보도",
      "confidence": "high",
      "sources": [
        {"title": "...", "url": "...", "date": "2026-06-13", "publisher": "..."}
      ]
    }
  ]
}

```

Step 2 산출

```

json
{
  "keyword": "MLCC 공급부족",
  "stocks": [
    {
      "name": "삼성전기",
      "code": "009150",
      "market": "KOSPI",
      "proposed_by": ["claude", "gpt", "gemini"],
      "agreement_score": 3,
      "relation_reason": "고용량 MLCC 글로벌 점유율 상위, 수급 타이트 시 ASP 수혜",
      "relevance": "high",
      "market_cap_eokwon": 123456,
      "revenue_ttm_eokwon": 98765,
      "per_ttm": 15.3,
      "per_quarterly_annualized": 12.1,
      "data_asof": "2026-06-13"
    }
  ]
}

```

`proposed_by`는 KRX 검증을 통과한 모델만 기록, `agreement_score`는 그 길이.
`relation_reason`·`relevance`는 judge 모델이 정리한 최종값.

모든 종목 객체는 F2.2 검증을 통과한 것만 포함. 미검증 LLM 제안은 별도 **dropped** 배열로 로깅.

7. 아키텍처 / 파이프라인

```
[collect] 네이버뉴스 + 컨센서스
  | raw_articles.json
  ▼
[extract] Claude → 테마/키워드 JSON
  | themes.json
  ▼
[map] 멀티 LLM(Claude·GPT·Gemini) 종목제안
  → 모델별 KRX 검증 → 코드 정규화 → 병합/합의도 → judge 사유정리
  | candidates.json
  ▼
[enrich] pykrx + DART → 시총/매출/PER 결합
  | enriched.json
  ▼
[report] HTML/Markdown 생성 (+ 알림 발송)
  | reports/YYYY-MM-DD/
  ▼
[schedule] GitHub Actions cron (주 1회)
```

각 단계는 **독립 모듈 + 중간 산출물(JSON) 저장** 구조로 만들어, 한 단계만 재실행/디버깅 가능하게 한다.

8. 기술 스택

- 언어: Python 3.11+
 - HTTP: requests 또는 httpx
 - 데이터: pandas
 - 금융데이터: pykrx, FinanceDataReader, OpenDartReader(또는 raw DART API)
 - LLM: anthropic SDK, openai SDK, google-genai SDK (제안자 인터페이스로 추상화, 설정으로 모델 on/off)
 - 리포트: Jinja2(HTML 템플릿), Markdown
 - 설정/시크릿: python-dotenv(로컬), GitHub Secrets(운영)
 - 스케줄: GitHub Actions (**on: schedule: cron**)
 - (선택) 알림: 텔레그램 Bot API 또는 SMTP
-

9. 비기능 요구사항

- **NF1 (검증):** LLM이 제안한 종목은 반드시 실제 상장 리스트와 대조. 미존재 종목은 리포트에 포함 금지.
- **NF2 (Rate limit):** 네이버 API·DART 호출 한도 준수. 재시도(backoff) 로직 포함.
- **NF3 (휴장일 처리):** pykrx 조회 시 직전 영업일로 자동 보정.
- **NF4 (오류 격리):** 한 키워드/종목 처리 실패가 전체 파이프라인을 중단시키지 않게 try/except + 로깅.
- **NF5 (재현성):** 모든 중간 산출물 JSON 저장, 동일 입력 재실행 가능.
- **NF6 (시크릿 관리):** API 키는 코드·리포지토리에 하드코딩 금지(.env / Secrets).
- **NF7 (데이터 신뢰성 표기):** 각 수치에 `(data_asof)` 날짜 기록, 분기 PER은 best-effort 라벨.
- **NF8 (멀티 LLM 정규화):** 각 모델에 "JSON only" 강제 + 방어적 파싱. 한 모델 실패·타임아웃 시 나머지 모델 결과만으로 진행(양상불 degrade 허용).

10. 개발 로드맵 (마일스톤)

단계	산출물	검증 기준
M1	뉴스·컨센서스 수집 모듈	키워드로 최근 N일 기사 N건 수집되는지
M2	Claude 테마 추출	themes.json이 스키마대로 생성되는지
M3	멀티 LLM 종목 제안 + KRX 검증	3개 모델 호출되고 가짜 종목이 걸러지는지
M3.5	양상불 병합 + judge	종목코드 dedup·agreement_score·최종 사유가 맞는지
M4	재무 결합(pykrx/DART)	시총·매출·PER이 실제값과 일치하는지
M5	리포트 생성	HTML/MD가 보기 좋게 렌더되는지
M6	GitHub Actions 자동화	매주 자동 실행·산출물 커밋되는지
M7	(선택) 알림 발송	텔레그램/이메일 수신 확인

원칙: M1부터 순차 구현하고 각 단계 산출물(JSON)을 눈으로 검증한 뒤 다음 단계로 진행. 한 번에 전체를 구현하지 않는다.

11. 리스크 & 완화

리스크	영향	완화
LLM 종목 환각(모델별)	잘못된 수혜주 노출	모델별 KRX 검증(NF1) + 합의도 낮은 종목 후순위
모델 간 제안 불일치	후보 난립	agreement_score 기준 정렬·필터, judge 최종 정리
멀티 LLM 비용·지연	호출 3배	주 1회 배치라 허용, 모델 on/off 설정으로 조절
컨센서스 사이트 구조 변경	크롤링 실패	셀렉터 분리·실패 시 뉴스만으로 동작
DART 분기 공시 시차	매출/분기 PER 부정확	data_asof 표기, 미공시 시 TTM만
API 한도 초과	수집 누락	backoff·캐싱·키워드 우선순위
테마 과다 추출	노이즈	confidence 임계값·키워드당 종목 상위 K 제한

12. 향후 확장 (Backlog, v0.1 이후)

- 키워드 히스토리 추적(주차별 등장 빈도 추이 차트)
- 동일 종목이 여러 주에 반복 등장 시 가중치
- 해외(미국/중국) 공급망 뉴스 소스 추가
- 간단한 웹 대시보드(주차별 리포트 열람)